




Juan Carlos Molero Rojas

plan_tesis_s_titulo_referencias

 AC-S18-PROY
 SJL-2025-1-CM-TALLER(PROYECTO)
 Investigación Lima

Detalles del documento

Identificador de la entrega

trn:oid:::1:3294598287

Fecha de entrega

12 jul 2025, 9:03 p.m. GMT-5

Fecha de descarga

12 jul 2025, 9:09 p.m. GMT-5

Nombre de archivo

plan_tesis_turnitin.pdf

Tamaño de archivo

405.4 KB

30 Páginas




5695 Palabras

32.442 Caracteres

5% Similitud general

El total combinado de todas las coincidencias, incluidas las fuentes superpuestas, para ca...

Fuentes principales

4%	 Fuentes de Internet
0%	 Publicaciones
1%	 Trabajos entregados (trabajos del estudiante)

Fuentes principales

- 4% Fuentes de Internet
- 0% Publicaciones
- 1% Trabajos entregados (trabajos del estudiante)

Fuentes principales

Las fuentes con el mayor número de coincidencias dentro de la entrega. Las fuentes superpuestas no se mostrarán.

1	Trabajos del estudiante	Universidad Nacional Federico Villarreal	1%
2	Internet	www.coursehero.com	<1%
3	Internet	pesquisa.bvsalud.org	<1%
4	Trabajos del estudiante	Ileria Online Blackboard	<1%
5	Internet	hdl.handle.net	<1%
6	Internet	repositorio.ucv.edu.pe	<1%
7	Internet	alicia.concytec.gob.pe	<1%
8	Internet	dtm.iom.int	<1%
9	Internet	proiser.com	<1%
10	Internet	www.criptored.upm.es	<1%
11	Internet	moam.info	<1%

12	Internet	repository.globethics.net	<1%
13	Internet	ri.ues.edu.sv	<1%
14	Internet	www.red-farmamedica.com	<1%
15	Internet	www.slideshare.net	<1%

Resumen

La detección de neumonía, dependiente de la interpretación manual de radiografías de tórax, enfrenta desafíos significativos como retrasos y errores diagnósticos, especialmente en contextos con escasez de especialistas. Este trabajo de investigación propone el diseño, implementación y validación de un modelo de deep learning bajo el paradigma de federated learning para mejorar la eficiencia diagnóstica. Se plantea la hipótesis de que el modelo mejorará significativamente la eficiencia en la Clínica San Juan Bautista. Para ello, se empleará un diseño cuasi-experimental pre-test/post-test; un modelo basado en redes neuronales convolucionales (EfficientNet) será entrenado y adaptado a un entorno clínico real utilizando el framework Flower para aprendizaje federado, garantizando la privacidad de los datos del paciente. La validación se realizará con una muestra de 51 pacientes, evaluando el tiempo de lectura, la precisión diagnóstica y la capacidad de priorizar casos graves. Las implicaciones de este estudio son ofrecer una herramienta tecnológica que no solo agiliza y precisa el diagnóstico de neumonía, sino que también respeta la confidencialidad del paciente, facilitando su adopción en diversos entornos clínicos y contribuyendo a optimizar la atención médica.

Palabras clave: deep learning, inteligencia artificial, federated learning, neumonía, radiografías de torax

Problema de investigación

La detección de neumonía a partir de radiografías sigue dependiendo en gran medida de la interpretación manual de especialistas, lo cual puede generar retrasos en el diagnóstico y, en ocasiones, equivocaciones de alta gravedad que ponen en riesgo la salud del paciente. Aunque herramientas tecnológicas han ganado terreno en algunas áreas, aún persiste una brecha significativa en la calidad de atención, especialmente en zonas rurales, donde la disponibilidad de médicos especializados es limitada.

El diagnóstico erróneo o tardío de neumonía tiene consecuencias graves, ya que puede derivar en complicaciones o incluso muertes, como se ha evidenciado en estudios previos. Por ejemplo, en un estudio realizado en Turquía, se observó que, debido a la sobrecarga de solicitudes durante la pandemia, la tasa de errores de interpretación alcanzó un 18.5% en los primeros 60 días del brote (Koc et al., 2021). Este tipo de error es aún más pronunciado en regiones rurales, donde el acceso a atención médica especializada es más limitado. De hecho, en Ecuador, la tasa de incidencia de cuadro neumónico adquirido en la comunidad fue de 16.83 por cada 10,000 habitantes en 2019, siendo los niños menores de cinco años y adultos mayores de 65 años los más afectados. La mortalidad hospitalaria oscila entre el 4% y el 18%, pero puede llegar hasta el 50% en casos graves que requieren ingreso en la Unidad de Terapia Intensiva (León Pallasco et al., 2023). Además, en Perú, durante diciembre de 2020, 61 de 149 clínicas y hospitales se encontraban sin capacidad para realizar diagnósticos, lo que reflejó la incapacidad del sistema de salud para responder adecuadamente a la crisis sanitaria (Comercio, 2020). Más recientemente, en 2024, el Instituto Nacional de Salud del Niño (INSN) enfrentó una grave

escasez de médicos radiólogos, lo que comprometió la capacidad del hospital para atender este tipo de consultas (Perú21, 2024). Además, según datos del Ministerio de Salud, existen 17 médicos por cada 10 000 habitantes, lo que genera sobrecarga y acceso limitado a servicios médicos, especialmente en zonas remotas donde más se necesita atención (Stakeholders, 2024).

Ante este panorama, cobra relevancia explorar cómo los modelos de deep learning pueden aportar una solución, lo que lleva a formular la siguiente interrogante: ¿En que medida el modelo de deep learning mejora la eficiencia de diagnóstico en los pacientes de la clínica San Juan Bautista 2026?

Objetivo general y específicos

1 Objetivo general

OG: Determinar en qué medida el modelo de deep learning mejora la eficiencia de diagnóstico en los pacientes de la clínica San Juan Bautista 2026.

Objetivos específicos

- **OE01:** Determinar en qué medida el modelo de deep learning reduce el tiempo de lectura de diagnóstico en los pacientes de la clínica San Juan Bautista 2026.
- **OE02:** Determinar en qué medida el modelo de deep learning mejora la precisión diagnóstica en los pacientes de la clínica San Juan Bautista 2026.
- **OE03:** Determinar en qué medida el modelo de deep learning mejora la priorización de casos graves en los pacientes de la clínica San Juan Bautista 2026.

Justificación

Teórica

Actualmente, existen numerosos estudios sobre la detección de enfermedades mediante Deep Learning. Con el paso del tiempo, los modelos se vuelven más precisos gracias al crecimiento constante del campo y la colaboración entre los autores en la literatura científica. Esta investigación busca compilar el conocimiento teórico más relevante, con el objetivo de obtener resultados óptimos y contribuir a que la inteligencia artificial se consolide como una tecnología confiable en el sector sanitario. Además, el estudio realizado servirá como base para trabajos de investigación futuros.

Práctica

La implementación de inteligencia artificial basada en visión por computadora no es una tarea sencilla y, cuando existen soluciones, suelen ser de pago. Este estudio busca desarrollar una herramienta gratuita que facilite el diagnóstico precoz de la neumonía, utilizando el paradigma de aprendizaje federado y el uso de las imágenes del sistema de manejo de imágenes diagnósticas de la clínica. De esta manera, se pretende que cualquier centro médico pueda acceder a esta tecnología, contribuyendo a salvar vidas y optimizar la atención médica, especialmente en áreas rurales.

Metodológica

El diagnóstico de neumonía se realiza comúnmente a través de radiografías de tórax, debido a su rapidez y bajo costo. Al tratarse de imágenes sin patrones simples y definidos, es fundamental emplear un algoritmo inteligente basado en redes convolucionales profundas. Esta

arquitectura es adecuada para el análisis de imágenes médicas por su capacidad de aprender patrones espaciales complejos. Esta investigación adopta un enfoque cuantitativo, ya que la efectividad diagnóstica será evaluada mediante indicadores de rendimiento que reflejan la capacidad del modelo para respaldar decisiones clínicas confiables.

2

Revisión de la literatura actual o estado del arte

Diversos estudios y proyectos han abordado la necesidad de desarrollar sistemas de detección de neumonía usando modelos de Deep Learning, demostrando su efectividad para diagnosticar la enfermedad.

Hwang y Park (2020) presenta una revisión sobre el uso de deep learning en radiología, con foco en radiografías de tórax y tomografías computarizadas. Introducir las aplicaciones clínicas del deep learning en la práctica diaria. Se realizó una revisión narrativa de literatura sobre algoritmos CNN y su integración en flujos clínicos. Se halló que el deep learning puede igualar o superar a radiólogos expertos en detección de enfermedades pulmonares, cribado, pronóstico y mejora de imagen. Aunque emergente, esta tecnología tiene alto potencial en radiología torácica, y su adopción requiere que los radiólogos comprendan sus capacidades y límites. Las barreras incluyen falta de explicabilidad, escasa validación clínica, poca evidencia de impacto en pacientes y dificultad de integración con sistemas existentes.

En estudios previos realizados por Kim et al. (2020), se evaluó un algoritmo comercial de deep learning para detectar neumonía en radiografías de tórax en pacientes de urgencias. Determinar el rendimiento diagnóstico del algoritmo y su utilidad como apoyo a médicos no radiólogos. Se estudiaron 377 pacientes en un hospital militar, comparando el desempeño del algoritmo con médicos de urgencias, con y sin asistencia, usando diagnóstico de radiólogos como referencia y midiendo el tiempo de lectura. Se evaluaron la *precisión diagnóstica*, el *tiempo de lectura del diagnóstico* y la *priorización de casos sospechosos*. El algoritmo superó a los médicos actuando solos y mejoró significativamente su rendimiento cuando se usó como

herramienta de apoyo. El deep learning mejora la detección de neumonía en urgencias y optimiza el flujo clínico cuando se integra como soporte diagnóstico. Las limitaciones incluyen una muestra poco representativa, pocos observadores, generación de falsos positivos y variabilidad individual en los beneficios clínicos.

Según la investigación de Sendak et al. (2020), integrar modelos de deep learning en la práctica clínica sigue siendo complejo, especialmente para enfermedades graves como la neumonía. Describir la implementación de Sepsis Watch, un sistema automatizado basado en deep learning para detectar y gestionar complicaciones infecciosas. En Duke Health se desarrolló un modelo predictivo e infraestructura con datos clínicos en tiempo real; se rediseñó el flujo de trabajo, se integró un equipo de enfermería para filtrar alertas y se aplicaron estrategias de gestión del cambio, formación y gobernanza clínica, evaluado con métodos mixtos. Se evaluó el *cumplimiento de tratamientos*, el *tiempos de respuesta de diagnóstico* y la *aceptación del sistema por el personal*. Sepsis Watch fue implementado con éxito en la práctica clínica real, gracias al compromiso del equipo médico y evitando el término "IA" para mejorar su aceptación. La adopción de IA requiere más que algoritmos: implica rediseño organizacional, capacitación, gobernanza y estrategias de aceptación que pueden guiar a otros centros. Las limitaciones incluyen realización en un solo centro, falta de datos sobre impacto clínico/económico, retos para reentrenar modelos y necesidad de validación en otros entornos.

Sim et al. (2022) explora el uso de IA para detectar infecciones pulmonares en radiografías torácicas tomadas en el periodo de la pandemia de COVID-19. Desarrollar y evaluar un modelo de IA que identifique neumonía con precisión, mida su impacto en la

práctica clínica real y en la rapidez de entrega de informes. Se utilizó un modelo DenseNet preentrenado con ChestX-ray14 y ajustado con más de 4,000 radiografías internas; fue integrado al flujo hospitalario para priorizar casos sospechosos, evaluado en 3,700 estudios clínicos y comparado con tiempos previos. Se midieron el *tiempo promedio de elaboración de informes*, el *rendimiento diagnóstico* y la *priorización de casos graves*. El sistema mantuvo su precisión en condiciones reales y redujo los tiempos de atención, demostrando utilidad en contextos clínicos de alta demanda. Se concluye que modelos de IA pueden integrarse eficazmente en el diagnóstico médico como filtro inicial, mejorando eficiencia sin comprometer la calidad, siempre bajo supervisión humana. Las limitaciones incluyen que fue implementado en un solo centro, no distingue tipos de neumonía, no usa datos clínicos adicionales y no está validado en población pediátrica.

Según la investigación de Kareem et al. (2023), se analiza el aprendizaje federado como método para entrenar modelos de detección de neumonía sin comprometer la privacidad de los datos médicos. El estudio busca desarrollar y evaluar un marco de FL que permita entrenar modelos de clasificación de neumonía con datos distribuidos, cumpliendo con normativas como GDPR y DPA. Se usaron 5,856 radiografías clasificadas como "neumonía" o "normal"; se entrenaron CNN (ResNet-50, DenseNet, AlexNet, VGG19, Inception) en cuatro clientes virtuales y se agregaron sus parámetros en un servidor central de forma iterativa. ResNet-50 bajo FL alcanzó 93% de precisión, comparable al entrenamiento centralizado; DenseNet también fue competitivo, mientras que AlexNet e Inception mostraron menor rendimiento. El estudio confirma que FL permite entrenar modelos efectivos para detectar neumonía

protegiendo la privacidad, destacando ResNet-50 y DenseNet como opciones viables para entornos colaborativos médicos. Se reportan desafíos como variabilidad de datos entre instituciones, carga de comunicación, falta de estandarización del FL y ausencia de certificación clínica para la solución propuesta.

En tal sentido Mabrouk et al. (2023), propone combinar aprendizaje por ensamble y federado para diagnosticar neumonía en radiografías sin comprometer la privacidad. El objetivo del estudio es diseñar y evaluar un marco de Aprendizaje Federado de Ensamble (EFL) que permita entrenar modelos robustos entre instituciones sin compartir datos sensibles. Para ello, se simuló cinco nodos, cada uno entrenó ocho CNN y seleccionó sus dos mejores para formar un Modelo de Ensamble Local (LEL); estos se enviaron a un servidor central para crear un Modelo de Ensamble Global (GEL), comparado luego con un enfoque centralizado. Como resultado, EFL alcanzó 96.63% de precisión, superando al modelo centralizado (95.03%) y mostrando mejoras consistentes sin comprometer privacidad. En conclusión, El aprendizaje federado de ensamble mejora la precisión del diagnóstico respecto a modelos centralizados y protege los datos, siendo aplicable a otras áreas médicas. Se enfrentan desafíos como la complejidad del marco EFL, riesgo de sobrecarga del servidor central y falta de heterogeneidad en la simulación de los nodos.

En tal sentido Riedel et al. (2023), propone ResNetFed, una versión de ResNet50 adaptada para aprendizaje federado con privacidad diferencial en la detección de neumonía por COVID-19 a partir de radiografías de tórax. El estudio busca evaluar la eficacia de ResNetFed, compatible con federated learning y privacidad diferencial, sin comprometer los datos clínicos.

Se usó el dataset COVIDx8 distribuido no-IID en cinco silos simulados; se modificó ResNet50 reemplazando la normalización por lotes con capas de identidad y se entrenó localmente, agregando actualizaciones con FedAvg durante 100 rondas, comparado con modelos locales y uno centralizado. ResNetFed alcanzó 82.82% de precisión, superando a los modelos locales (63%) y mostrando mejoras en silos con datos escasos, con menor precisión que el modelo centralizado (98%) pero mayor privacidad. En conclusión, se valida ResNetFed como una solución eficaz y segura en contextos clínicos descentralizados con datos distribuidos de forma no uniforme. Sin embargo, persisten desafíos como la distribución no-IID, ajuste de hiperparámetros, adaptación de arquitecturas y análisis limitado de datos sensibles.

Respecto a estudios de índole nacional se ha considerado el siguiente:

Flores Rodriguez y Cabanillas Carbonell (2022) evaluó el impacto de una app móvil con CNN para diagnosticar neumonía, enfocándose en acelerar la detección y aliviar la carga médica. Determinar la influencia de Diagnost (basada en DenseNet) en rapidez diagnóstica, precisión y reducción de asistencia médica. Se usó un enfoque experimental basado en evaluaciones pre y post a la intervención con grupos control y experimental (n=33), integrando el modelo en Android. Se evaluaron el *tiempo de detección*, la *precisión diagnóstica* y la *reducción de asistencia médica*. La app mejoró el tiempo diagnóstico y redujo la asistencia requerida, pero no aumentó la precisión respecto al grupo control. Diagnost fue útil para acelerar diagnósticos y optimizar recursos, aunque sin mejorar la precisión sobre métodos tradicionales. El modelo no alcanzó la precisión del personal médico, destacando la necesidad de mejorar técnicamente la herramienta.

Marco teórico

Fundamentos teóricos

10 En el desarrollo de un modelo para la detección de neumonía, es importante poder comprender las teorías y conceptos que fundamentan este desarrollo. A continuación, se presenta un análisis teórico que sustenta el proyecto, abordando aspectos esenciales como deep learning, neumonía, diagnóstico clínico, precisión de diagnóstico y tiempo de diagnóstico.

Un concepto importante a abordar es la enfermedad que se busca detectar, la neumonía.

3 Según Torres et al. (2016), se reconoce a la neumonía adquirida en la comunidad como una de las infecciones respiratorias más habituales y, si bien muchos pacientes pueden tratarse de forma ambulatoria, aquellos que requieren hospitalización presentan una mortalidad que oscila entre el 5% y el 15%, y esta puede aumentar hasta el 50% en quienes necesitan cuidados intensivos. Esta información pone en evidencia la severidad que puede alcanzar esta afección y subraya la necesidad de intervenir de manera temprana y certera para reducir complicaciones.

Gil D. et al. (2005) argumenta que el diagnóstico clínico de neumonía es la fase de identificación de la enfermedad, que, sin el respaldo de una radiografía torácica, resulta inexacto, dado que los síntomas y resultados físicos no permiten distinguir de manera precisa la neumonía de otras afecciones respiratorias graves. Por esta razón, el escritor resalta la importancia de los exámenes de imagen, como la radiografía, para corroborar el diagnóstico y prevenir fallos clínicos.

Como afirma (Agha et al., 2022), la eficiencia en el diagnóstico no se trata simplemente de reducir costos o realizar menos pruebas, sino de usar los recursos de manera óptima para

promover la salud del paciente. Aun un diagnóstico muy preciso podría no ser eficiente si el costo (financiero, físico o de tiempo clínico) de alcanzar esa precisión supera el valor clínico de detectar la enfermedad. Esta eficiencia implica equilibrar la reducción de errores diagnósticos con los riesgos y costos asociados a lograr mayor exactitud, incluyendo daños físicos por pruebas, tiempo del personal de salud y recursos del sistema. Además, destacan que decisiones diagnósticas eficientes deben considerar el contexto clínico, el valor del tratamiento tras el diagnóstico y el impacto potencial sobre el bienestar del paciente.

En cuanto a la precisión de diagnóstico, Balogh et al. (2015) sostiene que la precisión diagnóstica se entiende como un componente esencial de la exactitud. Un diagnóstico es considerado impreciso, y por ende inexacto, cuando carece de los detalles suficientes para describir adecuadamente la condición del paciente. Los autores destacan que el proceso diagnóstico es de naturaleza iterativa, lo que significa que su propósito es ir refinando progresivamente la comprensión del problema de salud. Este refinamiento busca reducir la incertidumbre inicial para llegar a una explicación que sea, en última instancia, más precisa y completa. De este modo, la precisión no es solo una característica deseable, sino un pilar fundamental para evitar el error diagnóstico, ya que asegura que la explicación final refleje fielmente la verdadera situación del paciente.

A continuación, Launay et al. (2016) establecen el tiempo de diagnóstico como el lapso temporal que se extiende desde la aparición de los primeros síntomas de alerta en un paciente hasta la confirmación formal del diagnóstico. El significado de este concepto supera el simple registro del tiempo, pues los autores lo descomponen en intervalos específicos que permiten un

14 análisis más detallado, como el tiempo atribuible al paciente (desde la aparición de los primeros síntomas hasta el momento de la atención médica inicial) y el tiempo atribuible al sistema sanitario (desde el primer contacto médico hasta el diagnóstico final). El estudio de este indicador es fundamental para identificar los determinantes, ya sean del paciente o del sistema de salud, que pueden alargar este periodo. De esta manera, el tiempo de diagnóstico se convierte en una herramienta analítica para evaluar su impacto en los resultados clínicos.

En cuanto a la priorización de casos graves, Déry et al. (2020) mencionan que, la priorización de pacientes se define como el proceso de clasificar derivaciones clínicas en un orden específico según criterios explícitos, con el propósito de favorecer un acceso más justo y transparente a los servicios de salud en situaciones donde las necesidades de atención superan los recursos disponibles. Además, los autores argumentan que esta acción es beneficiosa porque permite intervenir primero en quienes presentan mayores necesidades clínicas o mayor riesgo de deterioro, reduciendo así el potencial de secuelas físicas o psicológicas derivadas de una espera prolongada.

Con el propósito de definir la tecnología que a utilizar, Goodfellow et al. (2016) lo definen como un subconjunto del machine learning centrado en algoritmos inspirados en las redes neuronales artificiales, que buscan modelar representaciones jerárquicas de los datos, permitiendo que las máquinas comprendan conceptos más complejos. De manera similar, Chollet (2017) explica el deep learning como un enfoque que permite a las máquinas aprender a través de la experiencia, entendiendo el mundo mediante una jerarquía de conceptos.

continuyendo

Para poder asegurar la privacidad de los datos y entender cómo lograr este objetivo en un entorno clínico real, es importante definir el paradigma de federated learning. Yurdem et al. (2024) lo definen como una técnica de aprendizaje automático distribuido que permite que varios dispositivos o nodos colaboren en el entrenamiento de un modelo común sin compartir los datos originales. En lugar de centralizar los datos, cada participante entrena localmente y solo envía actualizaciones del modelo, lo que mejora la privacidad, seguridad, eficiencia y escalabilidad del proceso. Además, Bharati et al. (2022) complementan esta idea describiéndolo como un sistema en el que un agregador central coordina los esfuerzos de múltiples clientes para resolver problemas de aprendizaje automático. En este enfoque, los datos de entrenamiento se mantienen dispersos en los dispositivos de los usuarios, lo que permite proteger la privacidad. El entrenamiento del modelo se realiza localmente en cada dispositivo y, en lugar de compartir los datos brutos, solo se intercambian los gradientes o parámetros del modelo con el servidor central, salvaguardando así la información privada de cada participante.

Para abordar la escasez de datos etiquetados en tareas clínicas específicas, lo cual es un desafío común en el sector salud, es crucial emplear estrategias que aprovechen el conocimiento preexistente de modelos ya entrenados. Ali et al. (2023) definen el transfer learning como una técnica de aprendizaje automático cuyo objetivo es mejorar el rendimiento en una tarea específica, conocida como tarea objetivo, al utilizar el conocimiento adquirido de una tarea fuente distinta pero relacionada, para la cual sí se dispone de una mayor cantidad de datos. En esencia, en lugar de entrenar un modelo desde cero, esta técnica transfiere características, parámetros o representaciones aprendidas previamente, permitiendo que el

nuevo modelo generalice de manera más efectiva y evite el sobreajuste, incluso cuando se enfrenta a un conjunto de datos limitado para la nueva tarea.

Para optimizar modelos que ya poseen una base de conocimiento general, se recurre a técnicas de ajuste especializado que permiten refinar su rendimiento sin necesidad de un reentrenamiento completo. En este contexto, Lalor et al. (2017) describen el fine-tuning como un enfoque de entrenamiento innovador donde un modelo previamente entrenado se ajusta utilizando un conjunto de datos suplementario y especializado. Esta técnica aprovecha las representaciones y el conocimiento que el modelo ya ha aprendido de un gran corpus de datos y lo especializa para una tarea más concreta mediante la actualización de sus parámetros con este nuevo conjunto de datos, que es más pequeño y específico. El enfoque principal es la mejora del desempeño y la capacidad latente del modelo en su dominio original sin afectar negativamente su capacidad de generalización. Lalor et al. (2017)

Hipótesis

Hipótesis general

5 **HG:** El modelo de deep learning mejora significativamente la eficiencia de diagnóstico en los pacientes de la clínica San Juan Bautista 2026.

Hipótesis específicas

- **HE01:** El modelo de deep learning reduce significativamente el tiempo de lectura de diagnóstico en los pacientes de la clínica San Juan Bautista 2026.
- **HE02:** El modelo de deep learning mejora significativamente la precisión diagnóstica en los pacientes de la clínica San Juan Bautista 2026.
- **HE03:** El modelo de deep learning mejora significativamente la priorización de casos graves en los pacientes de la clínica San Juan Bautista 2026.

Metodología

Diseño metodológico de investigación

Tipo de investigación

Este trabajo se clasifica como un estudio aplicado porque tiene el objetivo de implementarse y demostrar su eficacia en entornos reales. Según Hernández Sampieri y Fernandez Collado (2014), las investigaciones aplicadas son aquellas que buscan resolver problemas prácticos y específicos de la realidad, para servir como insumo clave en la toma de decisiones o a la solución de situaciones concretas en contextos determinados.

Enfoque

Esta investigación tiene usa un enfoque mixto porque los indicadores tiempo de diagnóstico y precisión de diagnostico son de tipo cuantitativo, mientras que el indicador de satisfacción del médico es de tipo cualitativo. De acuerdo con Creswell (2020), existen tres tipos de enfoque: el cualitativo, que es un enfoque destinado a revelar el sentido que los individuos o grupos otorgan a una problemática de índole social o humana; el cuantitativo, que busca probar teorías examinando la relación entre variables medidas con instrumentos y analizadas estadísticamente; y el mixto, que se sitúa en un punto intermedio porque integra componentes tanto del enfoque cualitativo como del cuantitativo.

Diseño

Este estudio adopta un diseño cuasi-experimental, ya que tiene como propósito medir los resultados obtenidos tras la aplicación de una intervención en dos grupos principales, mediante mediciones realizadas antes y después de la misma. Como señala Shadish et al. (2020),

el diseño cuasi-experimental se identifica por intentar establecer relaciones causales cuando no es posible asignar aleatoriamente a los participantes a los grupos de comparación, utilizando en su lugar otros métodos para controlar amenazas a la validez interna.

Nivel / Alcance

El estudio que se presenta es explicativo ya que busca comprender cómo los modelos de deep learning pueden identificar la presencia de neumonía en imágenes médicas. Según Guevara Alban et al. (2020), la investigación explicativa se enfoca en establecer relaciones de causa y efecto, y no se limita a describir o explorar un fenómeno, sino que intenta descubrir los factores que lo provocaron.

Población

El presente estudio toma como población a 1000 pacientes atendidos en la clínica San Juan Bautista 2026, que presentan sintomatología respiratoria compatible con infecciones pulmonares como neumonía. Según Willie (2024), la población en una investigación se entiende como el conjunto de individuos que comparten características dentro de un contexto geográfico o institucional determinado, y compone la base para formular hipótesis relevantes al estudio.

Muestra

El estudio realizado usa el tipo de muestra no probabilística con el método por conveniencia, ya que se seleccionarán 51 pacientes disponibles en la Clínica San Juan Bautista, con quienes se tiene acceso directo para aplicar y validar el modelo de detección de neumonía sin necesidad de una selección aleatoria. De acuerdo con Willie (2024), la muestra corresponde a una parte representativa del total de la población general, seleccionado por criterios para

lograr el objetivo de investigación. Además, citando a Ahmed (2024), existen tipos de muestra como el muestreo no probabilístico el cual se trata en la selección no aleatoria de los participantes y dentro de sus técnicas, se encuentra el muestreo por conveniencia que consiste en seleccionar a quienes están más fácilmente disponibles.

Técnicas

La presente investigación utiliza la técnica de observación porque se busca estar presente durante la fase de experimentación en la clínica, permitiendo anotar directamente los resultados y el comportamiento del modelo en tiempo real. Citando a Medina et al. (2023), la técnica de observación consiste en registrar el comportamiento, acciones o eventos observados directamente en el entorno donde se desarrollan, permitiendo obtener datos objetivos y directos del entorno.

Instrumentos

Este estudio hará uso del instrumento de ficha de observación porque permite registrar de forma estructurada los resultados del modelo de diagnóstico aplicado a cada paciente. En palabras de Medina et al. (2023), la ficha de observación es de los instrumentos más utilizados en trabajos de investigación, cuya función es documentar detalladamente lo observado según categorías previamente definidas, facilitando así su análisis posterior.

Análisis de datos

En el presente estudio, se organizará y procesará la información recolectada inicialmente en un archivo de hoja de cálculo, para facilitar la preparación del conjunto de datos para el uso en el modelo. Se realizará un análisis descriptivo Python y Pandas, a fin de

explorar la distribución de los datos y verificar su integridad antes del entrenamiento. Según

15 Sarker (2021), el análisis de datos se refiere al procesamiento de datos mediante teorías y herramientas estadísticas, empíricas o lógicas, con el fin de extraer información útil con propósitos prácticos.

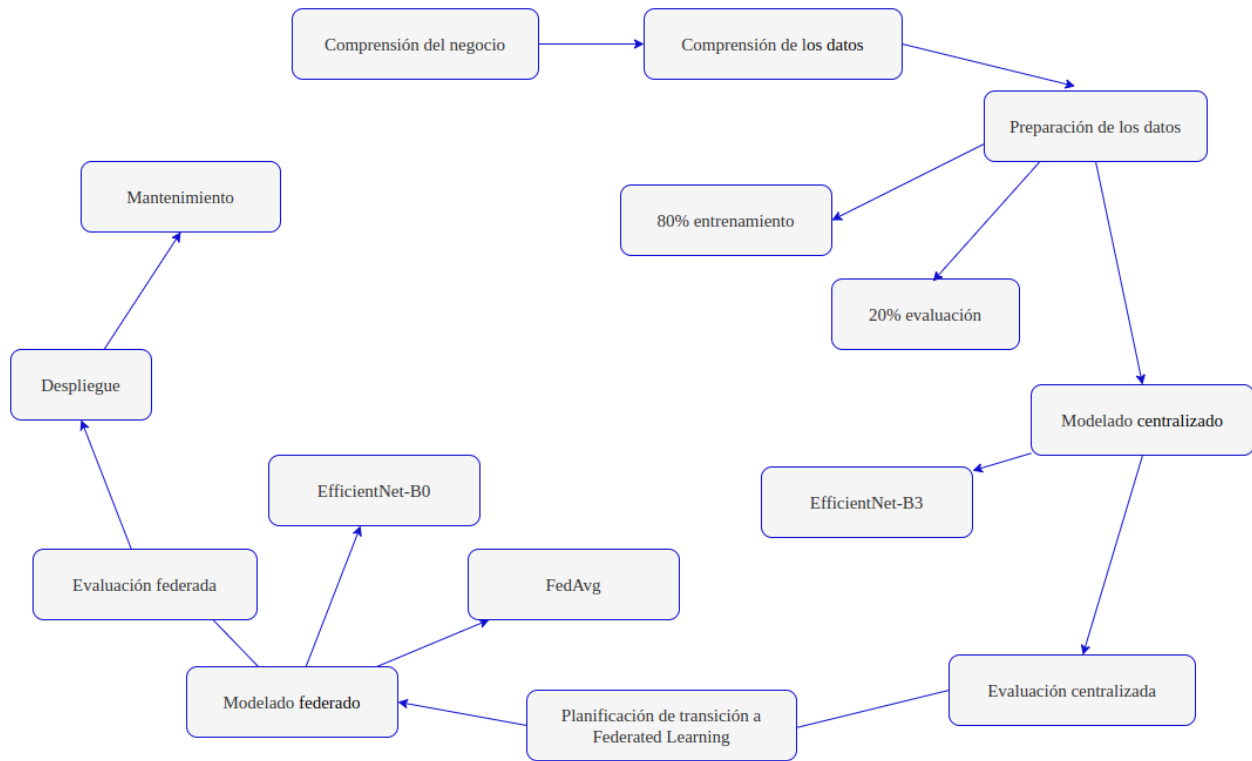
Aspectos éticos

Este estudio considera los aspectos éticos fundamentales, asegurando que los datos clínicos utilizados serán tratados con estricta confidencialidad y exclusivamente con fines de investigación. Durante la validación del modelo en la clínica, se garantizará el anonimato de los pacientes y se solicitará consentimiento informado. Según Farhud y Zokaei (2021), antes de 2 implementar Inteligencia Artificial en contextos clínicos, se deben considerar principios éticos fundamentales como la autonomía, la beneficencia, la no maleficencia y la justicia.

Metodología seleccionada

Figura 1

Diagrama de metodología basado en CRISP-DM (Elaboración propia)



Comprensión del negocio

Durante esta etapa se analizar el impacto de lo objetivos del proyecto teniendo en cuenta las restricciones de un ambiente privado como una clínica, además de explicar por que se considera una futura transición al paradigma de aprendizaje federado.

Comprensión de los datos

En esta etapa se analizará la fuente de datos de Kaggle «Chest X-Ray Images (Pneumonia)», se explorará su estructura y calidad, y se identificarán posibles diferencias entre los conjuntos distribuidos que influirán en la fase federada.

Preparación de los datos

En este punto del proceso se limpiarán, transformarán y normalizarán los datos.

Además, se establecerán formatos comunes y particiones simuladas para reflejar una posible distribución federada.

Modelado centralizado

En esta etapa se entrenará el modelo de EfficientNet-B3 utilizando todos los datos de forma centralizada, para utilizarlo como base para comparaciones futuras.

Evaluación centralizada

Durante esta instancia se evaluará el modelo centralizado mediante métricas de rendimiento comunes para modelos de machine learning y su aplicación en la clínica San Juan Bautista.

Planificación de transición a Federated Learning

En esta etapa se definirá la estrategia de comunicación cliente-servidor usando el framework Flower y se adaptará el modelo centralizado para entrenamiento distribuido.

Modelado federado

A esta altura del procedimiento se implementará y entrenará el modelo en un entorno federado, utilizando múltiples nodos con datos locales, y aplicando el algoritmo FedAvg.

Evaluación federada

Durante esta secuencia se analizará el desempeño del modelo federado utilizando métricas de rendimiento, tanto a nivel global como por cliente.

Despliegue

En este punto del proceso se desplegará el modelo en producción en un servidor en la nube de AWS y establecer un cliente para futuros nodos.

Mantenimiento


Por último, en esta etapa se llevará a cabo el monitoreo del modelo en el tiempo, incluyendo reentrenamientos periódicos automatizados, incorporación de nuevos clientes y ajustes ante cambios en los datos.

Cronograma

El siguiente cronograma detalla la planificación temporal del desarrollo del plan de tesis. Se incluyen tanto las actividades vinculadas a la formulación y redacción del plan de investigación, como las correspondientes al desarrollo técnico del proyecto basado en deep learning y federated learning. Cada etapa se ha organizado secuencialmente para asegurar un flujo de trabajo ordenado y coherente.

Figura 2

Diagrama de gantt (Elaboración propia)



Presupuesto

La presente sección detalla el presupuesto destinado a la ejecución del proyecto de investigación. Este contempla los costos relacionados con software, conectividad, materiales, capacitación, validación, y otros gastos asociados al desarrollo, implementación y evaluación del modelo de deep learning aplicado al diagnóstico de neumonía, incluyendo su posterior adaptación al enfoque de Federated Learning. A continuación, se presenta la estimación de costos:

Tabla 1

Tabla de presupuesto destinado al desarrollo del estudio (Elaboración propia)

Categoría	Descripción	Cantidad	Costo unitario (S/.)	Subtotal (S/.)
Software	Licencia de Google Colab Pro	6 meses	35.50	213.00
Software	Uso de GPU en nube para entrenamiento	30 horas	4.00	120.00
Material	Impresiones y empastado de tesis	2	30.00	60.00
Transporte	Visitas a centro de salud para validación	4	5.00	20.00
Instrumentos	Fichas de observación impresas	51	1.00	51.00
Recursos	Conectividad a internet	6 meses	60.00	360.00
Equipo	Laptop personal	1 unidad	0.00	0.00
Capacitación	Cursos de capacitación en Platzi	3 meses	149.00	447.00
Otros gastos	Imprevistos	1 unidad	80	80
Total estimado				1351.00

Anexos

Figura 3

Diagrama de Ishikawa (Elaboración propia)



Matriz de consistencia (Elaboración propia)

1	Problemas	Objetivos	Hipótesis	Variables	Dimensiones	Metodología
7	¿En que medida el modelo de deep learning mejora la eficiencia de diagnóstico en los pacientes de la clínica San Juan Bautista 2026?	Determinar en que medida el modelo de deep learning mejora la eficiencia de diagnóstico en los pacientes de la clínica San Juan Bautista 2026.	el modelo de deep learning mejora significativamente la eficiencia de diagnóstico en los pacientes de la clínica San Juan Bautista 2026.	Variable independiente: el modelo de deep learning Variable dependientes: <ul style="list-style-type: none"> eficiencia de diagnóstico tiempo de lectura de diagnóstico precisión diagnóstica priorización de casos graves 	<ul style="list-style-type: none"> eficiencia de diagnóstico tiempo de lectura de diagnóstico precisión diagnóstica priorización de casos graves 	Tipo: Aplicada Enfoque: Cuantitativo Nivel: Explicativo Diseño: Experimental (pre y pos) Técnica: Observación Instrumento: Ficha de observación Población: 1000 pacientes del hospital SISOL Muestra: 51 pacientes Muestreo: Probabilístico simpleo simpleo simple Muestreo: Probabilístico simple
	¿En que medida el modelo de deep learning reduce el tiempo de lectura de diagnóstico en los pacientes de la clínica San Juan Bautista 2026?	Determinar en que medida el modelo de deep learning reduce el tiempo de lectura de diagnóstico en los pacientes de la clínica San Juan Bautista 2026.	el modelo de deep learning reduce significativamente el tiempo de lectura de diagnóstico en los pacientes de la clínica San Juan Bautista 2026.	<ul style="list-style-type: none"> precisión diagnóstica priorización de casos graves 		
	¿En que medida el modelo de deep learning mejora la precisión diagnóstica en los pacientes de la clínica San Juan Bautista 2026?	Determinar en que medida el modelo de deep learning mejora la precisión diagnóstica en los pacientes de la clínica San Juan Bautista 2026.	el modelo de deep learning mejora significativamente la precisión diagnóstica en los pacientes de la clínica San Juan Bautista 2026.			
	¿En que medida el modelo de deep learning mejora la priorización de casos graves en los pacientes de la clínica San Juan Bautista 2026?	Determinar en que medida el modelo de deep learning mejora la priorización de casos graves en los pacientes de la clínica San Juan Bautista 2026.	el modelo de deep learning mejora significativamente la priorización de casos graves en los pacientes de la clínica San Juan Bautista 2026.			

6 Matriz de operación de variables (Elaboración propia)

Variables	Definición conceptual	Definición operacional	Indicadores	Escala	Técnica / Instrumento
Variable independiente el modelo de deep learning	Un modelo de deep learning es un subconjunto del machine learning centrado en algoritmos inspirados en las redes neuronales artificiales, que buscan modelar representaciones jerárquicas de los datos, permitiendo que las máquinas comprendan conceptos más complejos (Goodfellow et al., 2016).				
Variable dependiente eficiencia de diagnóstico	La eficiencia de diagnóstico es la capacidad de un proceso diagnóstico para maximizar los beneficios clínicos para el paciente utilizando de manera óptima los recursos disponibles, equilibrando la precisión diagnóstica con los costos, riesgos (Agha et al., 2022).	Esta variable será evaluada mediante sus respectivos indicadores: eficiencia de diagnóstico, tiempo de lectura de diagnóstico y precisión diagnóstica. Para ello, se aplicarán fichas de observación a la muestra en dos momentos distintos: antes (preprueba) y después (postprueba) de la intervención.	tiempo de lectura de diagnóstico $TL = \frac{\sum_{i=1}^n t_i}{n}$ Donde: TL = Tiempo de lectura t_i = Tiempo de lectura del caso i n = Número total de casos evaluados precisión diagnóstica $PD = \frac{VP}{VP+FP} * 100$ Donde: PD = Precisión diagnóstica VP = Verdaderos positivos FP = Falsos positivos priorización de casos graves $CP = \frac{CPC}{TC} * 100$ Donde: CP = Casos graves priorizados CPC = Casos graves correctamente priorizados TC = Total de casos graves evaluados	De razón	Observación Fichas de observación

Figura 4

Diagrama de arquitectura de software (Elaboración propia)

